Implementação de rede neural hierárquica de aprendizado profundo para cálculo de interpolações por elementos finitos

Estudante: Pedro Azevedo Coelho Carriello Corrêa

Orientador: Dr. Pablo Giovanni Silva Carvalho

EESC/USP

pedroazevedo@usp.br

Objetivos

Nessa pesquisa, são utilizadas redes neurais informadas pela física do tipo multi-layer *perceptron* para aperfeiçoar o método de elementos finitos aplicados em um contexto ilustrativo de mecânica dos sólidos e analisar, até certo escopo, a acurácia das soluções encontradas e a influência de parâmetros relevantes para a configuração do método.

Inspirado nos artigos Saha et al. (2021) e Zhang et al. (2021), o projeto visa a formulação e o teste de um método que utiliza uma rede neural hierárquica para realimentar a localização dos nós de uma malha de elementos finitos.

Essa realimentação viria do treinamento da rede e, a partir dela, é esperado que os elementos finitos ficam mais refinados nas regiões de maior sensibilidade da solução, ou seja, os nós iriam se concentrar nas regiões que a solução mais flutua, de modo a diminuir seu erro, enquanto regiões mais lineares da solução não concentrariam tantos elementos.

Métodos e Procedimentos

Os principais modelos de redes neurais e métodos de aprendizado de máquina foram introduzidos ao aluno por meio do curso das disciplinas SCC0230 - Inteligência Artificial e SCC0270 - Redes Neurais e Aprendizado Profundo, ministradas, respectivamente, pela Profa. Solange Oliveira Rezende e Prof. Moacir Antonelli Ponti.

Posteriormente, foi aprofundado o estudo de PINNs (*Physics-Informed Neural Network*) a partir de artigos como o Sharma et al. (2023) e vídeo-aulas na internet.
Já o método de elementos finitos foi estudado principalmente a partir da leitura de Becker e etc. (1981).

Uma primeira versão do algoritmo foi feita em linguagem *Python*, utilizando a biblioteca *PyTorch*, focada em machine learning, além de outras bibliotecas auxiliares. Porém, após certas dificuldades no uso do da biblioteca, principalmente no seu pacote *autograd*, a implementação do algoritmo foi migrada para o *Matlab*, sendo que, neste, a implementação do treino da rede foi feita manualmente, sem o uso de demais bibliotecas.

Para a formulação do método, foi considerada a função de forma chapéu e redes neurais em paralelo para cada um dos nós cujas saídas são o análogo dessa função de forma. Assim:

$$u_h(x) = \sum_{i=1}^{N} u_I \phi_i(x) = \sum_{I=1}^{n} \mathcal{N}(\mathbf{W}, \mathbf{b}, \mathcal{A}, x) u_I$$

Resultados

O problema para aplicação do modelo foi um dos exemplos do artigo Zhang et al. (2021). Neste exemplo, há uma barra na posição horizontal engastada nas suas duas extremidades e submetida a uma força vertical de b(x):

$$b(x) = -\frac{4\pi^2(x-2.5)^2 - 2\pi}{e^{\pi(x-2.5)^2}} - \frac{8\pi^2(x-7.5)^2 - 4\pi}{e^{\pi(x-7.5)^2}}$$

Após o treinamento da rede, a posição dos nós da malha em comparação com a solução exata se tornou a seguinte:

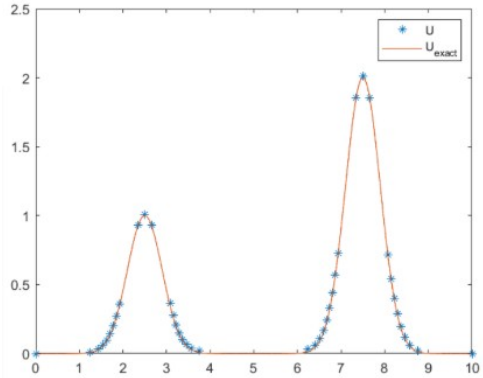


Figura 1: Posição dos nós no final do treinamento

Além disso, foi analisado o impacto de alterações de parâmetros do otimizador utilizado para o treinamento da rede sobre o aprendizado do modelo.

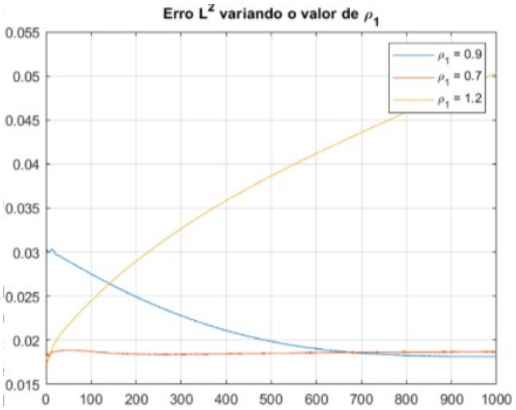


Figura 2: Erro L² em função de um dos parâmetros do otimizador

Conclusões

O modelo estudado consegue de fato encontrar uma solução próxima da solução exata e alterar as posições dos nós, assim como o desejado.

É possível afirmar, pelo estudo, que o modelo analisado reflete a grande versatilidade da metodologia de redes neurais, que consegue funcionar bem mesmo em um contexto não relacionado a uma coleta de um grande bancos de dados, mas apenas utilizando equações matemáticas regidas pela física.

Agradecimentos

Dr. Pablo Giovanni Silva Carvalho, pela sua ajuda com seu conhecimento em elementos finitos e ajuda na pesquisa bibliográfica; Prof. Dr. Fabrício Simeoni de Sousa, que cedeu o acesso ao seu laboratório no ICMC para a realização da pesquisa; e aos Dr. Lei Zhang e Ph. D. Wing K. Liu, que gentilmente responderam dúvidas sobre vários pontos do seu *framework* de redes neurais hierárquicas de aprendizado profundo, que foi base para a implementação do algoritmo aqui utilizado.

Referências

BECKER. E. B.; etc. **Finite Elements: v. 1: An Introduction.** Harlow, England: Longmand Higher Education, 1981

SAHA, S.; GAN, Z.; CHENG, L.; GAO, J.; KAFKA, O. L.; XIE, X.; LI, H.; TAJDARI, M.; KIM, H. A.; LIU, W. K. Hierarchical deep learning neural artificial network (HiDeNN): An intelligence computational (AI) science framework for and engineering. **Comput. Methods Appl. Mech. Eng.**

ZHANG, L.; CHENG, L.; LI, H.; GAO, J.; YU, C.; DOMEL, R.; YANG, Y.; TANG, S.; LIU, W. K. Hierarchical deep-learning neural networks: finite elements and beyond. **Comput. Mech.**

SHARMA, P.; CHUNG, W. T.; AKOUSH, B.; IHME, M. A review of physics informed machine learning in fluid mechanics. **Energies**